## 先進計算機構成論 07

東京大学大学院情報理工学系研究科創造情報学専攻 塩谷亮太 shioya@ci.i.u-tokyo.ac.jp

- 一つだけ気になったのは、予測の入力としてPC以外のものは使えないのでしょうか?PCとその履歴以外を予測として使ったモデルはこれまでにあったか、ということが気になります。予測に使える情報は多ければ多いほど良さそうに感じました。
- レジスタの値、デコードで分かる情報(分岐命令の種類など)、値予 測を利用するような、分岐履歴とPCの値以外の情報を使う分岐予測 器は研究、または実用されていないのでしょうか?

質問ができるほど理解できなかったので資料を読み返します。静的 分岐と動的分岐でどのように機構が異なるのかが抑えられていない です。分岐予測の処理はIFのステップ中に行われるという認識で 合っていますか?

- MPKIという概念が興味深かったです。スパコンのFLOPSの場合はSCというカンファレンスで毎年そのランキングが発表されますが、MPKIでもそのような場はあるのでしょうか?
- グローバル予測器の履歴長がハードウェアの制約の関係で数kエントリ程度しか保持できないという点について、これは各分岐ごとにそのくらいの履歴長を保持しているということですか?分岐が非常に多いコードになった時にとんでもない量の記録を保持しないといけなくなるのではと思ったのですが…

- ハッシュパーセプトロンでHLが短いうちに正解をいわない場合には それほど効果がないように思った。
- 先生がローカル予測器とグローバル予測器を紹介していたとき、 ずっと「機械学習手法を使うなら楽じゃないか」と考えていました が、本当にパーセプトロン予測器がよく利用されてますね!やはり 機械学習が予測することにぴったりだと思います。

■ 履歴が貯まる前の分岐に対して、成立/不成立の両方を実行できるように回路を並べておいて、要らなくなったデータを捨てるというのは非現実的なんでしょうか?電力・回路的に無駄が多そうというのはなんとなく感じますが。

先週Virtual ISCAに参加しました。Microarchitectureセッションに幾つのbranch predictionやBTBの改善テクニックの論文が発表されたようです。やはりブランチ予測が現在のシステムのボトルネックになっていて、今後のトレンドにもなるのでしょうか?"

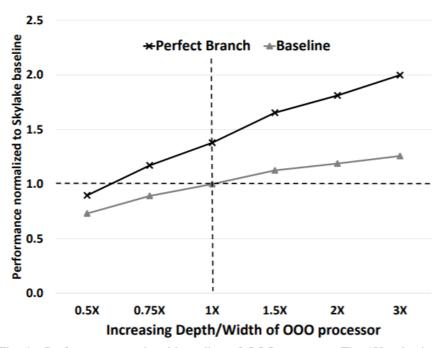


Fig. 1. Performance trends with scaling of OOO processor. The 1X point is similar in parameters to the Skylake processor [1]. Performance potential for future processors is bound by the problem of mis-speculation.

分岐予測を外した際に、外したとわかるまで行われた演算はどのように破棄しているのか気になりました。少なくともWBまでは行っていないので、レジスタ(もしくはキャッシュ?)に残されたデータをフラッシュするして消しているのでしょうか?

■ また、基礎的な質問で申し訳ないのですが、あるソフトウェアをコンパイルするときにそのアセンブリが命令メモリに格納されるアドレスは常に共通なのでしょうか。ローカル履歴を参照する分岐予測のやり方ではこれが成立していないとあまり機能しないのではないかと考えました。(そもそも言葉が正しいか不安なので、認識に誤りがあれば訂正をお願いします)

- 予測器がだんだん複雑になっていて、パーセプトロンなんかはかなり制約がありそうでしたが、予測器はどれくらいの速さで動く(結果を出す)のでしょうか。
- ローカル履歴予測器において、PCの下位16bitを使って履歴表を引いている理由はなぜでしょう。(上位がダメな理由は?)

■ PS4で独自CPUの採用を見送ったのは、ゲーム開発者からの声も あったからなんじゃないかと思っています。独自のCPUを使うモチ べとしては、簡単にエミュレートされないためとかもあると思うん ですが、それのせいで後続ハードへのゲームの移植が困難になって しまって、自身の首を絞める結果になっている感じがします。

- 分岐のパターンや異なる静的分岐の間にある相関などは、プログラム本体にも依存する気がしたのですがどうなのでしょうか。依存する場合、プログラマがコードを記述するときに何か意識することで分岐予測精度が上がったりするのでしょうか。
- 動画のデコーダーの開発をしていたときにif文を減らしたらキャッシュヒット率が上がって高速に動作するようになったという話がありましたが、どのくらいの速度の差が出たのでしょうか。一般的な話でも構わないのでキャッシュヒット率を向上させる努力によってどの程度性能が変わってくるのか知りたいです

■ The 1st Instruction Prefetching Championship 3位 入賞おめでとうございます。前も少しお話があったと思いますが、よければもう少し詳しくお話を聞きたいです。

#### The 1st Instruction Prefetching Championship

- ISCA の併設として開催
  - ◇ コンピュータ・アーキテクチャ分野で1番むずい国際会議の1つ
  - ◇ 提出するのは C++ の実装+論文で,査読有り
  - ◇ 6月初頭に発表
- https://research.ece.ncsu.edu/ipc/

## **D-JOLT** prefetcher

- 塩谷は坂井入江研の学生さんらと組んで出場
  - ◇ 3位入賞
- ポイント:
  - ◇ 関数の呼び出しと、そこからの復帰を起点にして命令をキャッシュに プリフェッチ
  - ◇ 関数の呼び出し履歴との相関の作り方
  - ◇ 2枚刃カミソリ的に,信頼度が違うプリフェッチャを時間差で発動してカバレッジをあげる

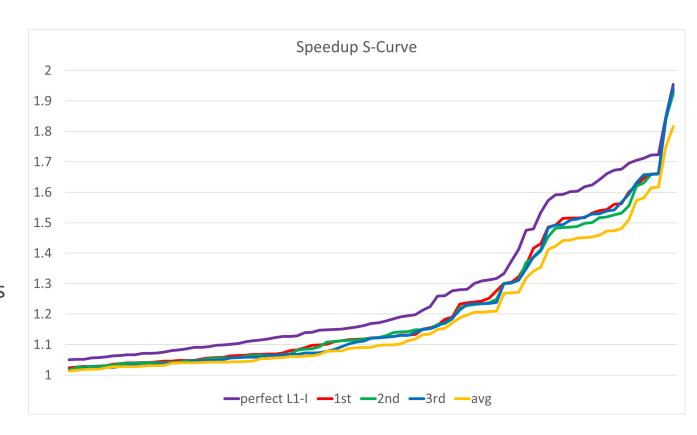
# Top 3 prefetchers ... (IPC1 Concluding Remarks より)

- 3<sup>rd</sup> place:
  - "D-JOLT: Distant Jolt Prefetcher" by Tomoki Nakamura, Toru Koizumi, Yuya Degawa, Hidetsugu Irie, Shuichi Sakai, Ryota Shioya (The University of Tokyo)
- 2<sup>nd</sup> place:
  - "The FNL+MMA Instruction Cache Prefetcher" by Andre Seznec (INRIA/IRISA)
- 1<sup>st</sup> place:
  - "Entangled Instruction Prefetcher" by Alberto Ros, Alexandra Jimborean (University of Murcia)

### Winners' S-curves (IPC1 Concluding Remarks より)

- 1<sup>st</sup>: 1.207x speedup
- 2<sup>nd</sup>: 1.201x speedup
- 3<sup>rd</sup>: 1.199x speedup

- 2<sup>nd</sup> and 3<sup>rd</sup> take turns having a higher Scurve
- 1st's S-curve is more consistently on top



#### 感想

- 出場者が全体にえぐかった
  - ◇ 予測器関係で歴史に名が残るレベルの仕事をしてきた人たちが多い
  - ◇ 平木先生「私達も Andre にはさんざん辛酸をなめさせられてきたからね~」
- うちらはまだあまりノウハウがない
  - ◇ この手の研究を始めたのが去年ぐらいから
  - ◇ 新設校が甲子園で準決勝に行ったぐらいの気分
- インテルから賞金が1000ドルもらえたが、コンプライアンスの関係で 東大を通しての受け取りになってしまった
  - ◇ ある程度ピンはねされる可能性が高い
- オンライン開催なので、終わった後の議論とか記念撮影ができなくて 残念

## Barça: Branch Agnostic Region Searching Algorithm Daniel A. Jiménez et al., より

- Barça is one technique. It does well by itself
- It would do better hybridized with other techniques
  - I dislike this approach because I cling to old-school notions of "elegance"
  - Also, industry doesn't like your hybrid designs. They get in the way of clarity
  - But elegance doesn't win optimization championships
- If I am unable to resist competing in the next championship like a moth to a flame I'll have to capitulate to hybridization

## 前回の内容

- 1. 分岐予測器全体の構造
- 2. 動的分岐方向予測

## 今日の内容

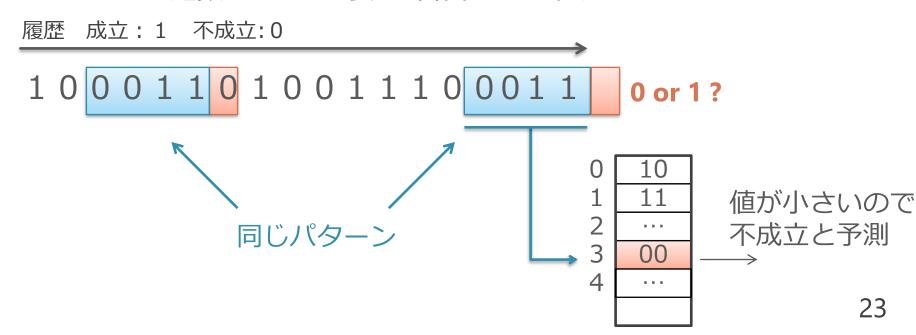
- 1. 分岐予測(最終回)
  - 1. 動的分岐方向予測の続き
  - 2. 間接分岐予測
- 2. メモリ

## 動的分岐方向予測の続き

- パーセプトロン予測器
- TAGE 予測器
- (より詳細はこの講義では扱いませんが,別ファイルの付録にまとめています.github (https://github.com/shioyadan/advanced-computer-organization)上からアクセスしてください.

## 前回の復習:「履歴(history)」を用いた予測器

- 基本的なアイデア:分岐方向の履歴をビット列で表す
  - ◇ 履歴のビット列をインデクスとしてテーブルにアクセス
    - □ テーブルのエントリは飽和型カウンタ
    - □ 成立時にインクリメント,不成立時にデクリメント
  - ◇ 直前の履歴でテーブルをひく
    - □ 直前に同じパターンがくると,同じエントリにアクセス
    - □ 二進数で 0011 = 表の3番目のエントリ



#### 履歴長と予測精度

- 一般に,グローバル履歴長を長くするほど精度はあがる
  - ◇ より遠い分岐の相関が拾えるようになる
  - ◇ 履歴長が1000以上のところに相関がある場合もある
    - □ ある関数で分岐した後, 色んな所にいってまた来るとか

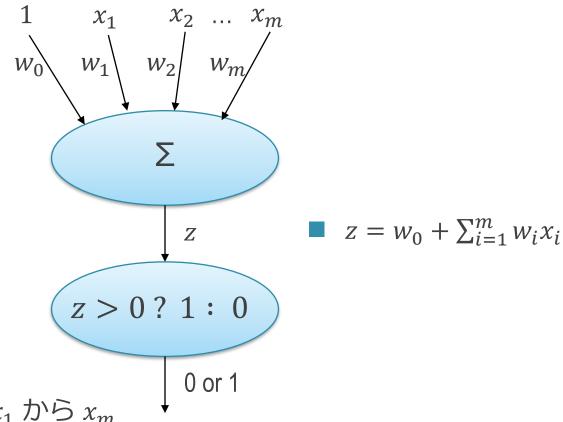
### 履歴長と予測精度

- 実際にはハードウェア(特に PHT の大きさ)の制約がある
  - ◇ 1サイクル内にアクセス可能な大きさに限られる
    - □ 最大数K エントリ程度
    - □ (最近はもうちょっと大きいかも)
  - ◇ 履歴長に対し、2の累乗のオーダーでエントリ数が増加
    - □ インデクスの最大値 = 2^履歴長 1
    - □ ハッシュ関数で折りたためば解決するが、出現パターン数が増えることには違いがない

## パーセプトロン予測器

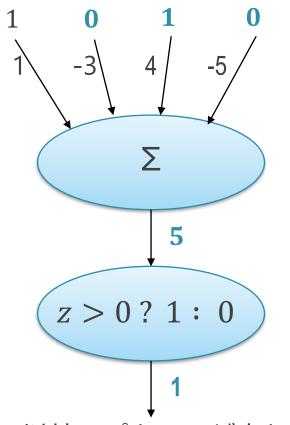
- モチベーション:
  - ◇ グローバル履歴のうち,本当に相関があるのは一部のビットのみ
  - ◇ ある特定の if 文同士で相関がある場合, 間の履歴は無駄
- パーセプトロン予測器:
  - ◇ 1層パーセプトロンを使って予測
  - ◇ 高速に予測を行う必要があるため、ややこしいことは無理
    - □ 1層限定で,重みは8ビット固定小数点とか
- 塩谷が学生の頃は半分ネタだと思われていたが, 今は実用化されている
  - ◇ AMD Zen はこれを使っている

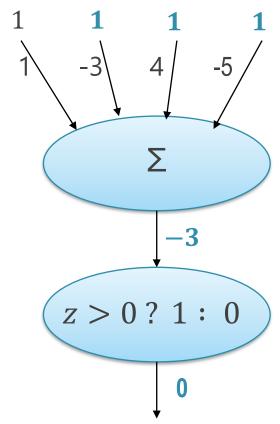
## パーセプトロン



- ◇ 入力(0 or 1): x₁からxm
- $\Diamond$  重み(アナログ値):  $w_0$  から  $w_m$ ( $w_0$  はバイアス)
- ◇ 学習:
  - $\square$  z が 1 の時,  $x_i$  が 1 だったなら  $w_i$  を大きく 0 だったなら  $w_i$  を小さくする

## 「010 なら1」を学習させた場合



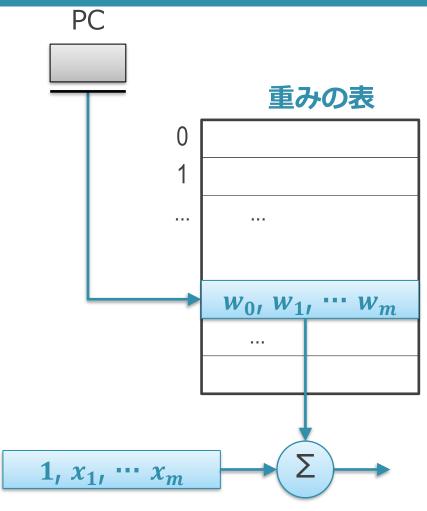


- 010 以外のパターンが来た場合は, z は負の方向に
- 左端はバイアス
  - $\langle z \rangle 0$ ?は、 $z < w_0$ ?に等価

## パーセプトロン予測器

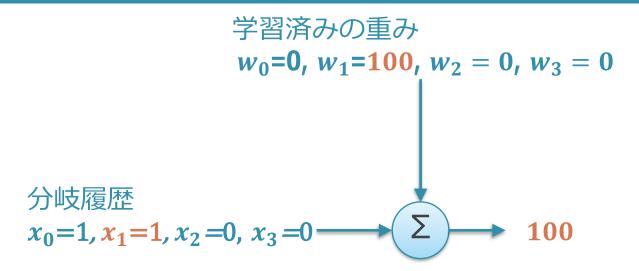
- 結構バリエーションがある
  - 1. グローバル履歴をそのまま重みにかけるもの
  - 2. g-share 的なテーブルから重みを出すもの
    - 1. Hash perceptron
    - 2. O-GHEL

## グローバル履歴をそのまま重みにかけるもの



- ◇ PC の一部をインデクスとして重み表をひく
  - □ その PC に対応した重みのセットがとれる
- $\Diamond$  あとはグローバル履歴を  $x_i$  としてパーセプトロンの処理を行う

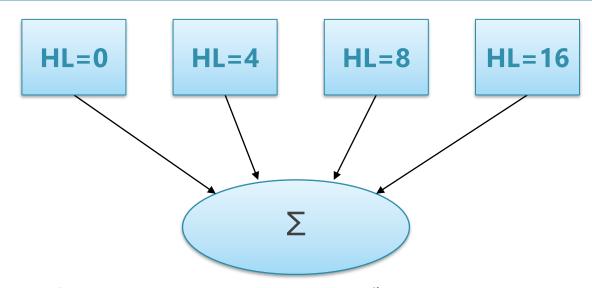
### 実際の学習の様子



- x<sub>4</sub> の方向を予測する
  - $\Diamond$   $x_4$  は  $x_2$   $x_3$  の方向とは関係なく,  $x_1$  の方向のみと相関する場合を考える
  - $\Diamond$   $x_1$  に対応する  $w_1$  の重みを大きく,それ以外の絶対値を小さくなるよう学習すればよい
    - □ 分岐方向に応じて毎回重みを加算/減算すれば, 成立に偏る場合は大きくなり,無相関な場合は0に近づく
  - $\Diamond$  内積をとると、 $x_1$  が 0 か 1 かにのみ応じて結果が変わる

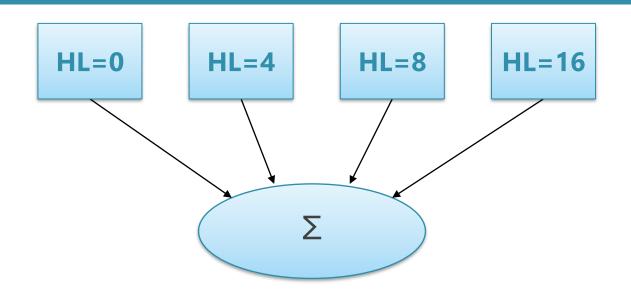
## **Hash perceptron**

(パーセプトロン予測器に分類されるが、前ページまでのものとはかなり違う)



- 履歴長(HL)が異なる g-share 様のテーブルを複数用意
  - ◇ 履歴 と PC の組み合わせでテーブルを引く
  - ◇ 中身は2ビットカウンタではなく,重み(8ビットなど)にする
- HL=4 のテーブルの場合
  - ◇ 4ビットの履歴と PC を XOR してそれをインデックスにしてアクセス
  - ◇ 8 ビットの重み(符号付き)が取れてくる
    - □ 符号なし2ビットにすれば本当にただのグローバル分岐予測器

## **Hash perceptron**

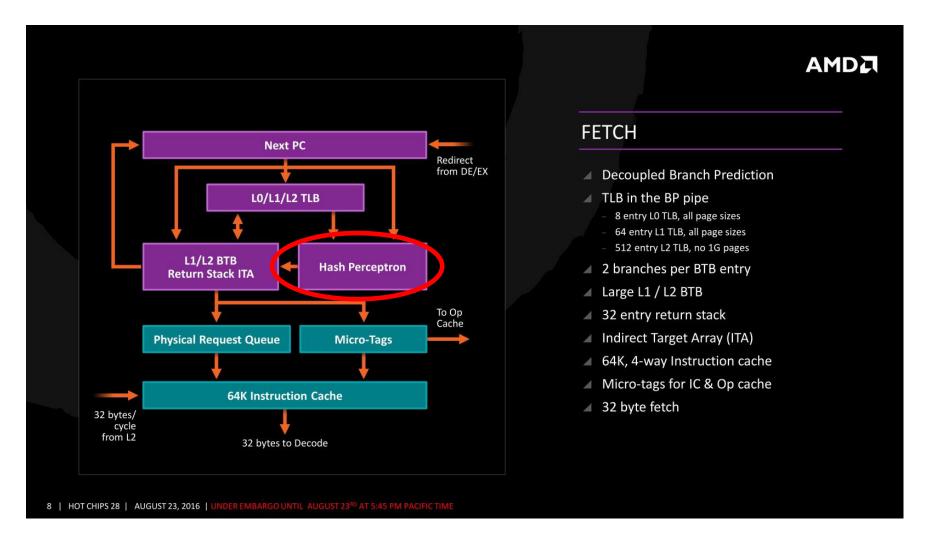


- 全員の出力を加算してパーセプトロンの処理
  - ◇ 通常のパーセプトロン予測器と違い,各テーブルから出てきた重みは そのまま加算される
  - ◇ 履歴と重みの内積はとらない
    - □ 履歴は各テーブルをアクセスするときに使用されている

## Hash perceptron の効果

- 正解を言うテーブルの重み(絶対値)が増えるように学習
  - ◇ そこより長い履歴のテーブルに学習されなくなる
  - ◇ 必要となるテーブルのエントリ数は2の履歴長乗に比例するので, なるべく履歴が短いテーブルだけで学習を済ましたい
- たとえば HL=0 が正解を言う(その PC はいつも成立とか)なら、 そこの重みを強く
  - ◇ HL=4 以降に学習されなくなる
- さらに発展として、HLの長さを動的に調整する O-GHEL 予測器というものもある

## AMD Zen では Hash Perceptron を使ってるらしい



■ HotChips 2016 の発表より

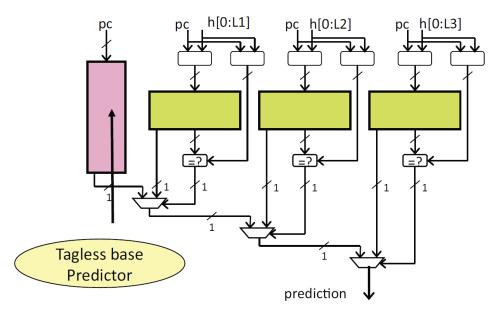
#### TAGE 予測器

#### ■ TAGE 予測器

- ◇ A. Seznec and P. Michaud. A case for (partially)-tagged geometric history length predictors, Journal of Instruction Level Parallelism (http://www.jilp.org/vol8), 2006
- 現在最も予測精度が高いと言われている予測器
  - ◇ 最近のインテルの CPU に乗っている… らしい
  - E. Rohou, B. Narasimha Swamy, A. Seznec
     Branch prediction and the performance of interpreters Don't trust folklore,
     2015 IEEE/ACM International Symposium on Code Generation and Optimization (CGO)
- モチベーション
  - ◇ 必要となるテーブルのエントリ数は2の履歴長乗に比例するので, なるべく履歴が短いテーブルだけで学習を済ましたい

#### TAGE 予測器

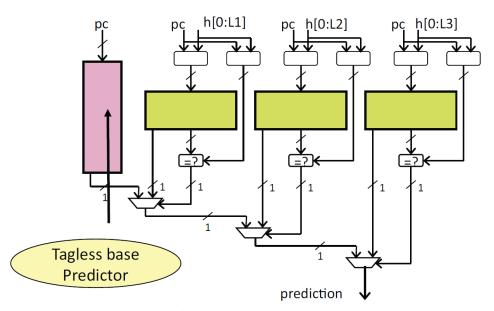
図は A. Seznec and P. Michaud. A case for (partially)-tagged geometric history length predictors より



- トーナメント式の構造:
  - ◇ 左端: 単純な2ビット・カウンタ
  - ◇ それ以外:
    - □ グローバル履歴+PC でアクセスし, BTB の時のように ヒット/ミス判定を行う
    - □ ヒットした場合, そのテーブルの n ビット・カウンタの内容で予測

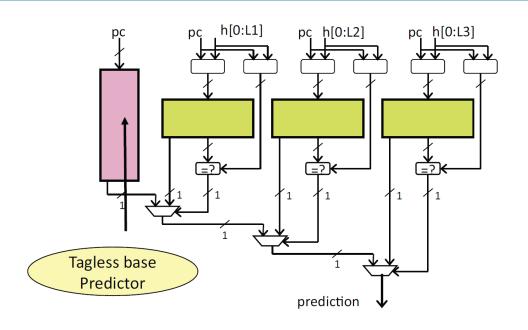
#### TAGE 予測器

図は A. Seznec and P. Michaud. A case for (partially)-tagged geometric history length predictors より



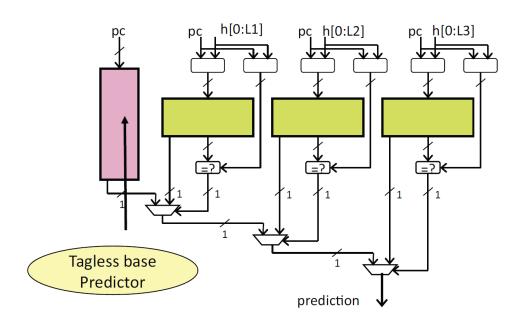
- パターン長が長いテーブルの結果を優先して使う
  - ◇ 右側でヒットするほど、その結果を優先する
  - ◇ 右に行くほど指数的に履歴長が長くなっている
- ヒット/ミスの判定ができるため、トーナメント状に優先度が 決定できる
  - ◇ ただの PHT だと、だれの結果を使えばいいかわからない

## TAGE 予測器のメリット(1)



- 利点1:パターン長ごとに、最適なテーブルに学習できる
  - ◇ たとえば 101 と 11111 の 2 パターンがあった場合
    - □ 固定長(5) : 00101, 01101, 10101, 11101, 11111
    - □ TAGE(3+5) : 101, 11111

## TAGE 予測器のメリット(2)



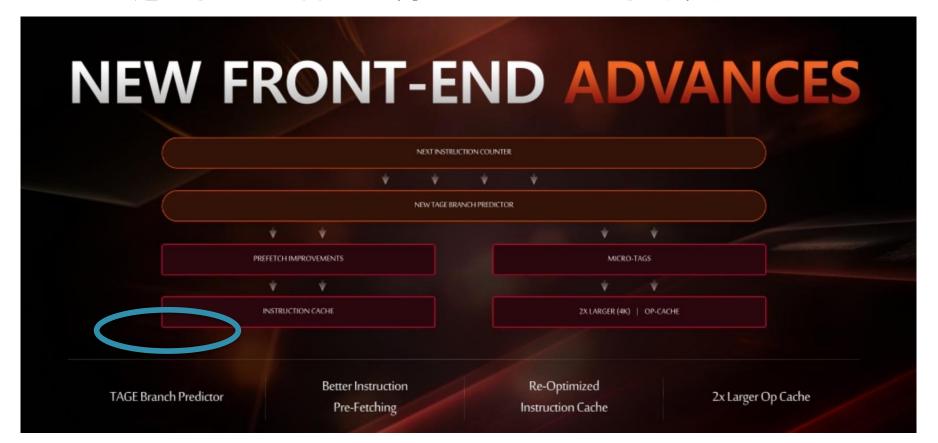
- 利点2:学習が早い
  - ◇ 大ざっぱに成立/不成立に傾向があるような場合,
  - ◇ 難しいパターンを学習する前に、とりあえず左端で大ざっぱな 予測ができる

#### TAGE 予測器 と パーセプトロン予測器

- それぞれ、今一番予測精度が高いと思われている
  - ◇ インテル、AMD の CPU で採用
- TAGE の方が、基本的には良い精度を示す
  - ◇ しかし, かなりのチューニングがいる
    - □ 特に各テーブルのサイズのバランスが難しい
  - ◇ ちょうどテーブルに履歴長が収まらず、はずみでガクッと精度が 落ちたりする
- パーセプトロン予測器は、結構適当でも大丈夫だし安定している
  - ◇ 企業の人的には、そこがありがたいらしい

## AMD Zen2 (Ryzen 9)

- 方向に分岐予測器に TAGE を導入したみたい
  - ◇ 実際は TAGE (低速高精度)とパーセプトロン(高速低精度)のハイブ リッドらしい
  - ◇ とりあえずパーセプトロンが言った方向でフェッチしておいて, 遅れて TAGE が言った方向が違ったらそっちでやり直す



## 最近の分岐予測器の研究

- TAGE をベースに、補助予測器(ループ専用、ローカル予測器、統計 的補正など)をつけたもの

  - ♦ Wormhole [Albericio14]
- TAGE の構造をより簡単にし、補正も入れずに同等の性能を出すもの
  - ♦ BATAGE [Michaud18]
- 近年でもさらに発展を続けている
  - ◇ 今日話した話の大半は A. Seznec と P. Michaud の 2 人の成果

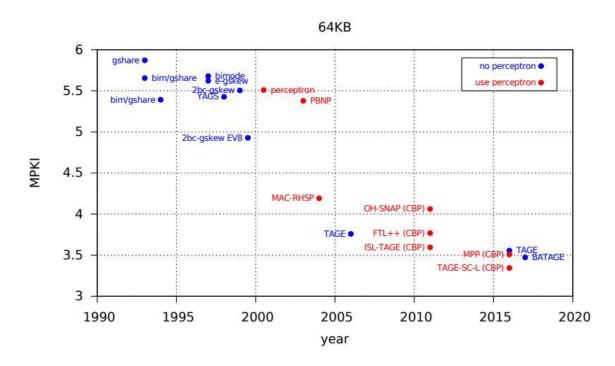


Figure 1: Average number of mispredictions per 1000 instructions (MPKI) for various conditional branch predictors on the CBP 2016 traces for 8KB, 32KB and 64KB storage budgets (see Appendix A).

#### 実際の例

- Adam Collura, Anthony Saporito, James Bonanno, Brian R. Prasky, Narasimha Adiga, Matthias Heizmann (IBM), The IBM z15 High Frequency Mainframe Branch Predictor, ISCA 2020
  - ◇ 汎用機むけの分岐予測器の実装
    - □ 通常の CPU とは少し前提が異なるのでちょっと注意
  - ◇ 汎用機(Main Frame):
    - □ 昔からある IBM の大型コンピュータのこと
    - □ 尋常じゃなく信頼性を重視して作られている
    - □ 銀行とかで今でも使われている
  - ◇ 実際の製品の中身について書かれたものとしては, 驚異的に詳しい
    - □ TAGE やパーセプトロンが実際に使われているようだ

# 今日の内容

- 1. 分岐予測(最終回)
  - 1. 動的分岐方向予測の続き
  - 2. 間接分岐予測

## 関節分岐命令

- ■方向分岐命令
  - ◇ 成立 or 不成立で行き先が分岐
  - ♦ bne x1, x2, TARGET
  - ◇ if 文に相当
- 関節分岐命令
  - ◇ レジスタに格納されているアドレスに飛ぶ
  - $\Diamond$  jr x1

## 関節分岐命令の使いどころ

- 関数ポインタ呼び出し,仮想関数呼び出し
  - ◇ 関数ポインタ変数やオブジェクト内の仮想関数ポインタをロード
  - ◇ ロードしたアドレスに間接分岐で飛ぶ
- switch-case 文
  - ◇ 例:0~255の256のパターンのcaseがある場合
  - ◇ 各 case の処理の先頭の命令アドレスを要素数 256 の配列に格納
  - ◇ 配列の要素をロードして、そこに間接分岐で飛ぶ
- return 文
  - ◇ 関数呼び出し時に、呼び出し元をメモリ上に保存
  - ◇ 呼び出し元アドレスをメモリからロードして, 間接分岐で戻る

# 間接分岐予測

- 1. 間接分岐一般の予測
- 2. 関数からの return の予測

#### 間接分岐一般の予測

- 基本的に間接分岐の予測は難しい
- 方向分岐:
  - ◇ 成立 or 不成立の 2 択を予測
  - ◇ 分岐先ターゲット・アドレスは不変
- 間接分岐:
  - ◇ 動的に変化しうる,無数にある分岐先アドレスを予測
  - ◇ 間接分岐の飛び先は, ロードした結果など = 64 bit などの値

#### 簡単なもの:BTB を使った間接分岐の予測

- 基本的には、「前回飛んだ先に今回も飛ぶ」と予測
- BTB に「分岐の種類」を表す1ビットを格納して予測する
  - ◇ 0:方向分岐 →
    - □ これまで説明した方法で予測
  - ◇ 1:間接分岐 →
    - □ 方向分岐予測の結果は無視
    - □ BTB の読み出し結果をそのまま使う
- BTB には前回に間接分岐を実行した際の飛び先が入っている
  - ◇ これを読み出してそのまま飛び先として予測

#### もう少し凝ったもの

- BTB を引くときのアドレスに履歴をまぜる
  - ◇ 方向分岐の, グローバル分岐履歴を使うものと同じ
  - ◇ 過去に辿ってきた分岐方向によって飛び先を変えることができる
  - ◇ ARM Cortex A15 などで搭載
- より発展させたものとしては、TAGE 予測器を応用したものなどが 提案されている

# 間接分岐予測

- 1. 間接分岐一般の予測
- 2. 関数からの return の予測

#### 関数からの return の予測

- 関数の call
  - ◇ 関数の先頭アドレスは固定
  - ◇ したがって,飛び先も固定
- 関数からの return
  - ◇ 同じ関数でも、呼び出し元は無数に存在
  - ◇ 直前に実行された call に戻ると期待できる
- 上記の性質を使って、return は高精度に予測できる

## Return Address Stack (RAS) を使った予測

- 使用する構造:
  - ◇ RAS :
    - □ 関数の呼び出し元を格納するスタック
  - ♦ BTB :
    - □ BTB の「分岐の種類」を表すビットを拡張
      - \* 関数コール or リターンであることを記録
      - \* デコードするまで、関数呼び出しであることはわからない
- 動作:
  - ◇ BTB 引きの結果が関数コール:
    - □ スタックにその時の PC + 4 (戻り先) を積む
  - ◇ BTB 引きの結果がリターン:
    - □ スタックのトップを読んで, そこに戻ると予測

# 今日の内容

- 1. 分岐予測(最終回)
  - 1. 動的分岐方向予測の続き
  - 2. 間接分岐予測

#### 2. メモリ

#### メモリ

- メモリ: RAM (Random Access Memory)
  - ◇ 複数のデータを記憶する回路
  - ◇ 配列のように,位置を指定して読み書きする
- なぜデータを記憶するための専用の構造が使われているのか?
  - ◇ D-FF とマルチプレクサでも同じ機能のものは作れる
  - ◇ メモリの方が圧倒的に速度や面積効率が高い
    - □ 後半で説明
- なぜメモリの構造を勉強するのか?:その性質の理解が重要だから
  - 1. 高度な CPU はメモリで作られた「表」を多用する
  - 2. 主記憶やキャッシュなどは直接メモリで作られる

## メモリ

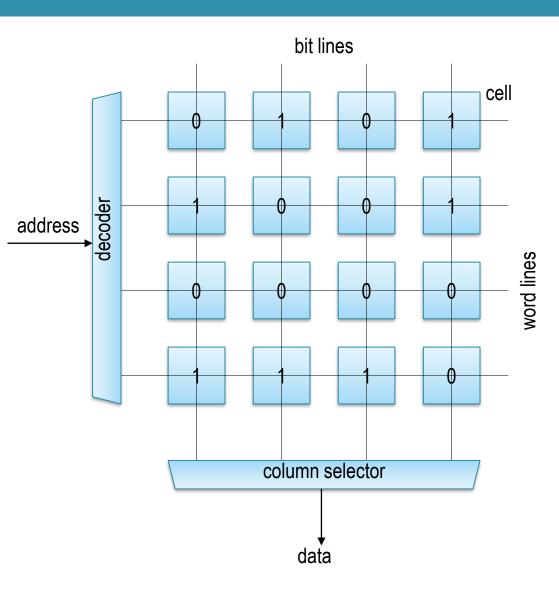
#### 1. メモリの基本

- 1. 構造
- 2. 動作
- 3. アクセス時間

#### 2. メモリの詳細

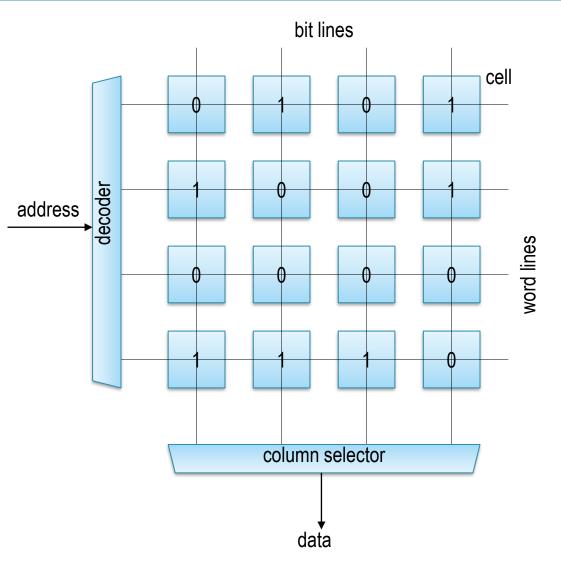
- 1. SRAM と DRAM
- 2. なぜメモリが存在するのか?
- 3. マルチポート・メモリ
- 4. メモリの脆弱性を対象にしたアタック
  - ☐ Raw Hammer, Cold Boot Attack

#### メモリの基本構造:セルを行列状に配置



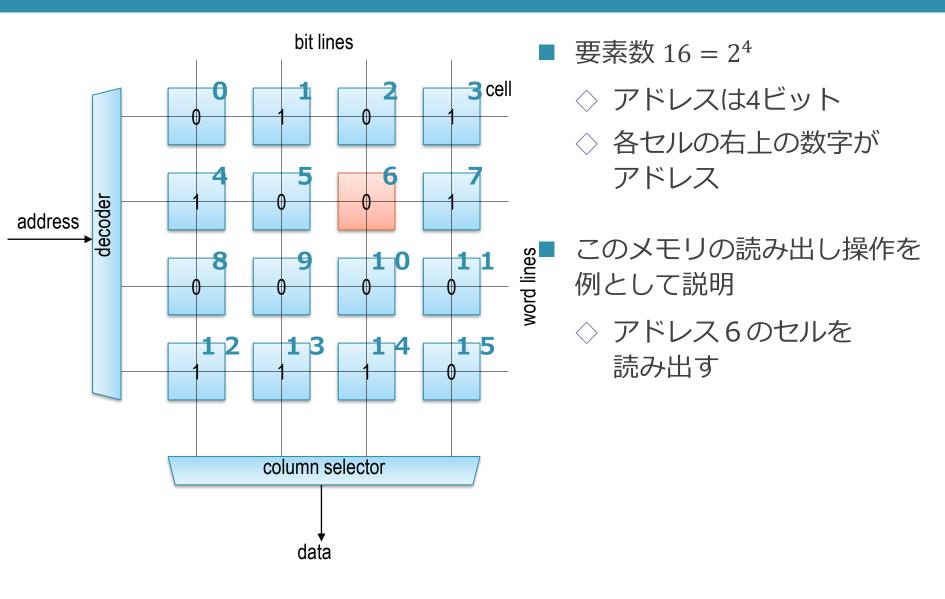
- ◇ セル:
  - □ 1ビットの情報を記憶
- ◇ ビットライン:
  - □ 列方向の配線
- ◇ ワードライン:
  - □ 行方向の配線
- ◇ デコーダ:
  - □ アドレスをデコードし てワードラインをア サート
- ◇ カラム・セレクタ:
  - □ ビットライン出力から 1つを選んで出力

#### メモリの読み出し操作

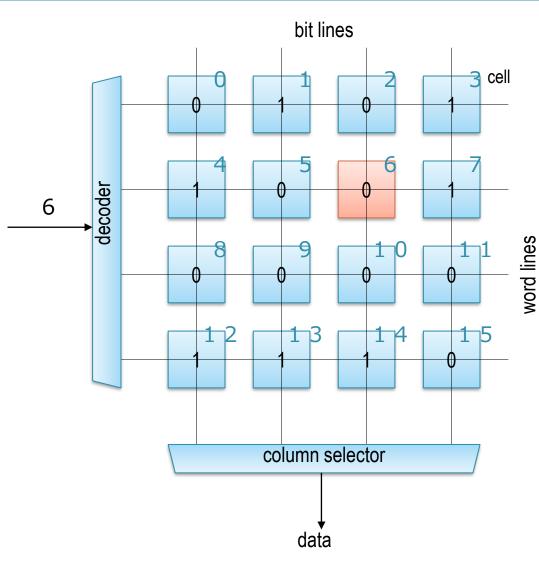


- 1. アドレスのデコード
- ワードラインのアサート (行の指定)
- ビットラインへの1行分のデータの読み出し
- 4. カラムセレクタによる 目的のビットの選択
- ◇ (書き込みはこれの逆を 行う

## メモリの読み出し動作の例



# メモリの読み出し動作(1) アドレスのデコード

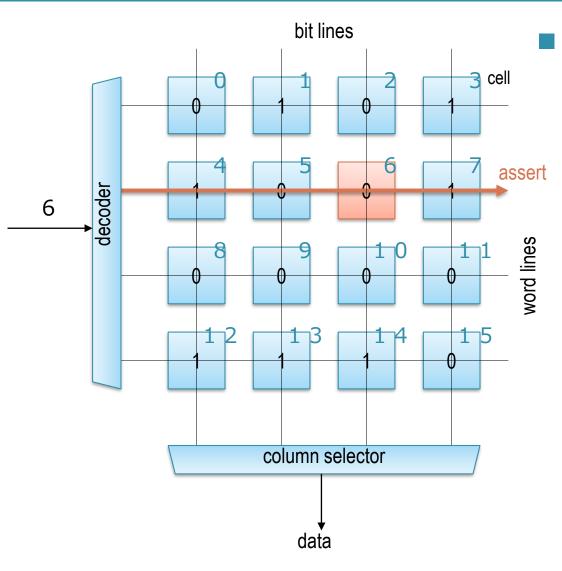


- どの行を読むか決める
  - ◇ 各行は4つセルがある
  - ◇ アドレスを4で割って 切り捨てた行目が 読むべき場所
  - ◇ 6 = 0110 (2 進数)

#### デコーダ

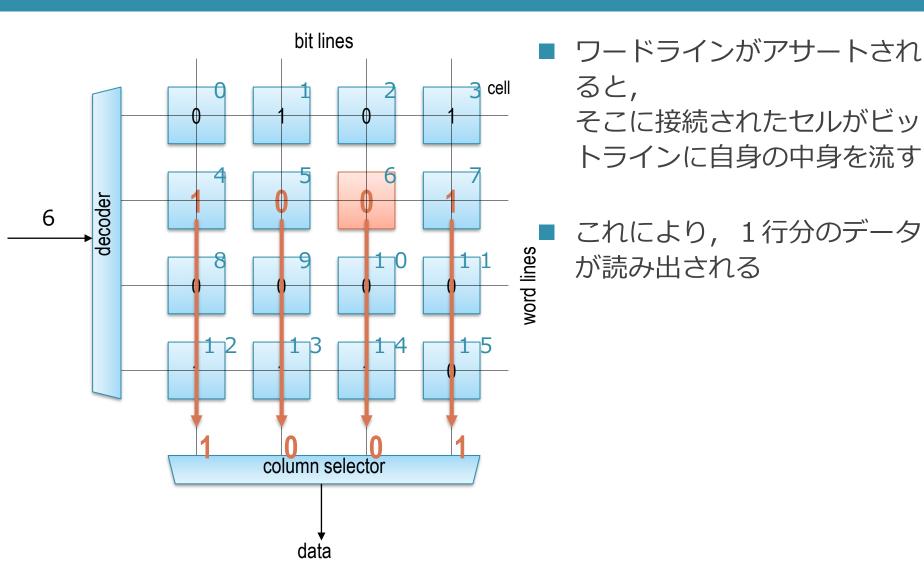
- ◇ 数字を対応するワンホット 信号に変換する回路
- ◇ ワンホット信号:
  - □ n 本のうち, 1つだけが 1で他が0の信号
- ◇ アドレス上位の2ビットを デコード 62

# メモリの読み出し動作(2) ワードラインのアサート

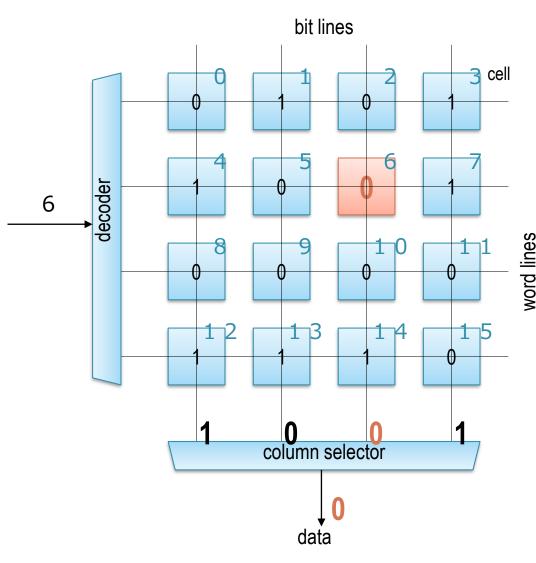


- 読み出す行に対応した ワードラインをアサート
- ◇ 先ほどのデコード結果を 使う

# メモリの読み出し動作(3)ワード(1行分のデータ)の読み出し



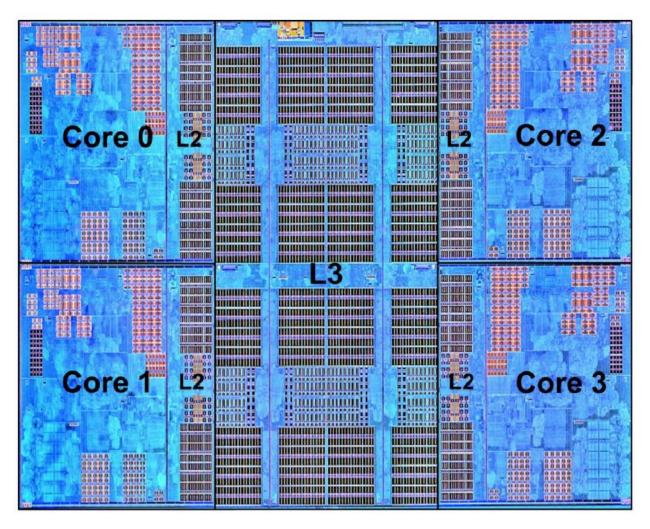
# メモリの読み出し動作(4) 列の選択



- 読み出された1行分のデータから,最終的に必要な1ビットを選択
- どの列を読むか決める
  - ◇ 各列は4つセルがある
  - ◇ アドレスを4で割った余り の列が読むべき場所
  - ◇ 6 = 0110 (2進数)
- カラム・セレクタにより ビットを選択する
  - ◇ 読み出し幅によっては この部分がないこともある

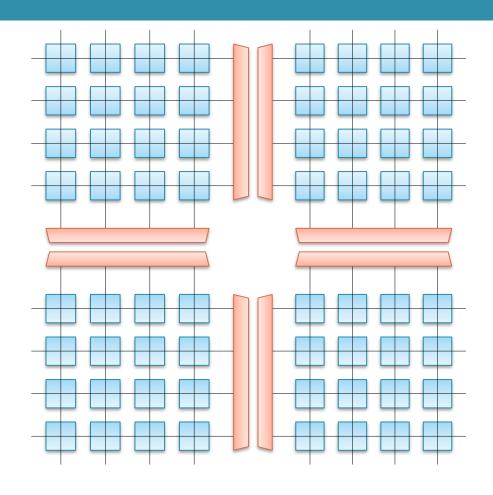
#### AMD Zen コアの場合

Teja Singh et al., Zen: An Energy-Efficient High-Performance ×86 Core より



- ◇ 赤や紫の「田」の字の構造の部分が全部メモリ(SRAM)
  - □ レジスタやキャッシュ,各種テーブルなど

#### 「田」の字の構造

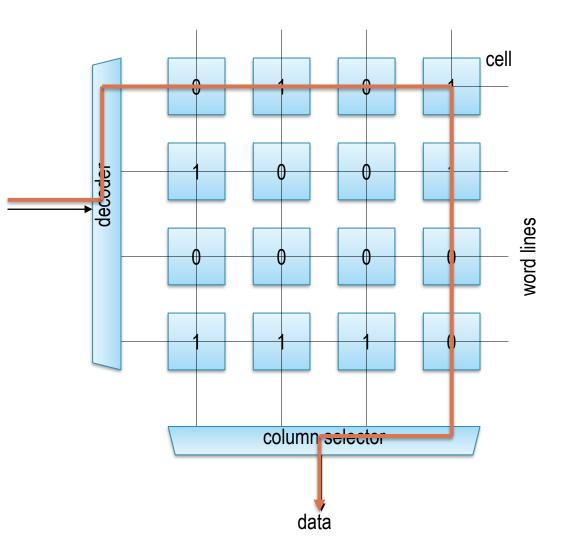


- 「田」の字の構造になっているのは,
  - ◇ 縦線がデコーダで左右に対してワードラインをアサート
  - ◇ 横線でビットラインのデータを拾う

## メモリ

- 1. メモリの基本
  - 1. 構造
  - 2. 動作
  - 3. アクセス時間
- 2. メモリの詳細
  - 1. SRAM と DRAM
  - 2. なぜメモリが存在するのか?
  - 3. マルチポート・メモリ
  - 4. メモリを対象にしたアタック

#### メモリの読み出し時間



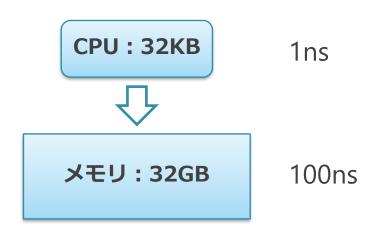
- メモリの読み出し時間:
  - ◇ 一番遠い経路を信号が 通るときの時間
- 容量(セルの数)が一定の 場合,正方形に近くするの が最も経路が短くなる

# データをとってくるのに, どのぐらいかかるか?



#### アクセス時間は容量に直接は比例しない

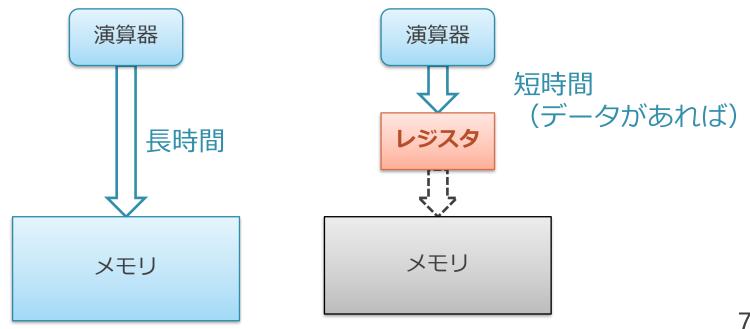
(容量の平方根ぐらいに比例



- 格子状に並んだセルの外周部の長さがアクセス時間を決めるから
  - ◇ メモリ容量 = (外周部の長さ)2
  - ◇ アクセス時間は,容量の 0.5 乗でしか伸びない

#### なぜレジスタやキャッシュがあるのか?

- 小容量だけど, 高速なレジスタやキャッシュを用意
  - ◇ 一度利用した値を入れておくことで,2度目からは高速に
- 大容量かつ高速なレジスタややキャッシュは作れない
  - ◇ 記憶容量に応じたアクセス時間が必要だから
  - ◇ 最終的には信号が伝わる長さに帰着する



## メモリ

#### 1. メモリの基本

- 1. 構造
- 2. 動作
- 3. アクセス時間

#### 2. メモリの詳細

- 1. SRAM と DRAM
- 2. なぜメモリが存在するのか?
- 3. マルチポート・メモリ
- 4. メモリを対象にしたアタック

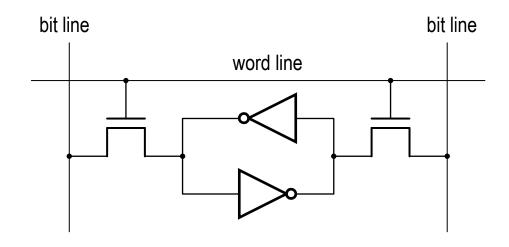
# メモリのバリエーション

- メモリは基本的にはみな同じ構造を取る
  - ◇ セルの中身が方式ごとに異なる
- SRAM と DRAM を紹介

### **Static Random Access Memory (SRAM)**

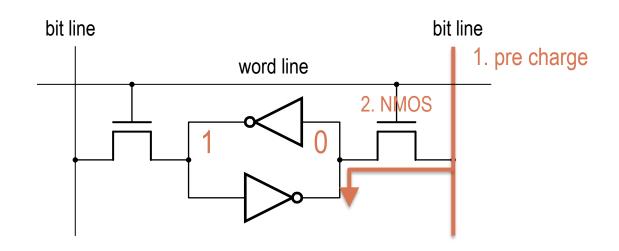
- Static とは:
  - ◇ 動作が静的(何もしなければ電流をほとんど消費しない)
  - ◇ 電源を入れている限りは内容が消えない
- 一般的にはメモリの中で最も高速
  - ◇ CPU 内の論理回路と同じトランジスタを使って作るから
  - ◇ レジスタやキャッシュ,各種テーブルは SRAM で作られている

### SRAM のセル(1bit)



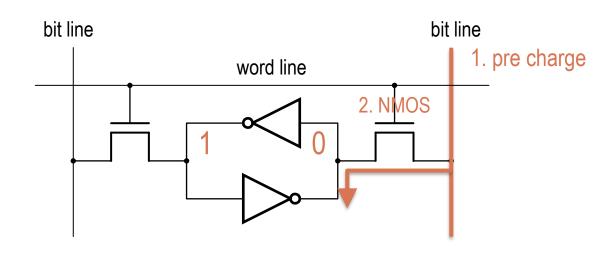
- インバータのループにより, 1 bit を記録
  - ◇ ループの左右が [1:0] あるいは [0:1] の 2 つの定常状態を持つ

#### SRAM の読み出し



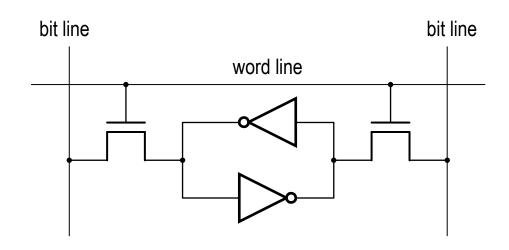
- 1. ビットラインのプリチャージ
  - □ ビットラインをあらかじめ高電位(1)にチャージする
- 2. ワードラインをアサート
  - □ ループの右にある NMOS が ON に
  - □ ループとビットラインが接続される
- 3. ビットラインのディスチャージ
  - □ ループの右が0なら,ビットラインが0に
  - □ ループの右が1ならそのまま

#### なぜプリチャージが必要なのか?



- 単にループとビットラインが接続されるだけではダメ
  - ◇ NMOS が高電位をうまく伝えられないから
    - □ もしループの右側が 1 で NMOS が ON になっても, ビットラインを 1 に引き上げることはできない
  - ◇ PMOS を追加すればできるが,なるべく小さく作りたいから嫌だ
- NMOS を介してビットラインの電位を下げることだけができる
  - ◇ = あらかじめ電位を上げておいて、下がったかどうかで判定

#### SRAM の書き込み



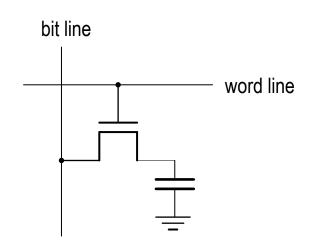
#### ■書き込み手順

- ループ左右のどちらか0にしたい方のビットラインの電位を下げる
- 2. ワードラインをアサートして NMOS を ON に
- 3. インバータの状態を強制的にビットライン側から低電位にする
- NMOS が低電位しか通せないので、書き込みには2本いる

#### **Dynamic Random Access Memory (DRAM)**

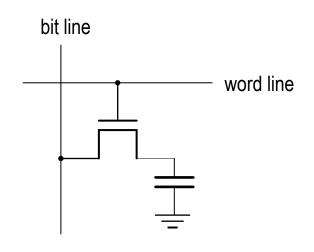
- 速度は遅いが、セルを小さく作れるので容量が稼げる
  - ◇ メイン・メモリは DRAM で出来ているのが普通

#### DRAM のセル



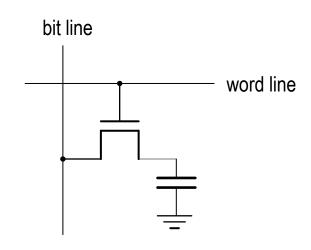
- セルをコンデンサによって構成
  - ◇ 電荷がたまっていれば1, そうでなければ0
  - ◇ 時間が経つと自然に電荷が抜けてデータが消える
- 電荷を維持するため、定期的にリフレッシュと呼ばれる操作を行う
  - ◇ 具体的には、一回読んで同じデータを書き戻す

#### DRAM の読み出し



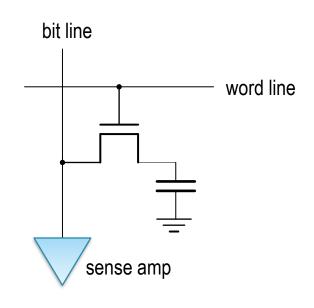
- 読み出しは、基本的には SRAM と同じ
  - ◇ ビットラインをプリチャージ
  - ◇ ワードラインをアサート
  - ◇ セルの状態に応じてディスチャージが起きる

#### DRAM の書き込み



- 書き込みは、NMOS でも 0.5 までは上げられるのでそれで行う(多分)
  - ◇ SRAM ではインバータをひっくり返す必要があるので, 0.5 ではダメだった
- DRAM では 低電位(0) or 中間電位(0.5) を記録する
  - ◇ 読み出し時のプリチャージの電圧を 0.5 にして,下がったかどうかで判定

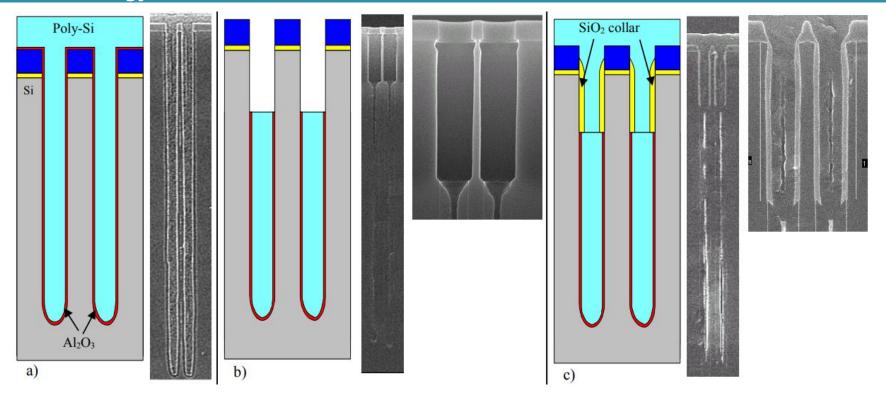
#### SRAM の場合との違い



- 読み出し時に内容が破壊される
  - ◇ ビットラインとコンデンサが接続されると, 電荷が流れ出す
- コンデンサがビットラインをディスチャージする速度は遅い
  - ◇ センスアンプと呼ばれる微小な電圧の変化を増幅する回路を使う

#### DRAM のコンデンサの作り方

H. Seidl et al, A Fully Integrated Al2O3 Trench Capacitor DRAM for Sub-100nm Technology より



- チップの表から裏に向けて深い穴を掘って表面積を稼ぐ
  - ◇ コンデンサの容量は表面積に比例
  - ◇ トレンチ(塹壕の意味)と呼ばれる
  - ◇ 特殊な工程が必要なので通常のトランジスタと混ぜて作るの が難しい

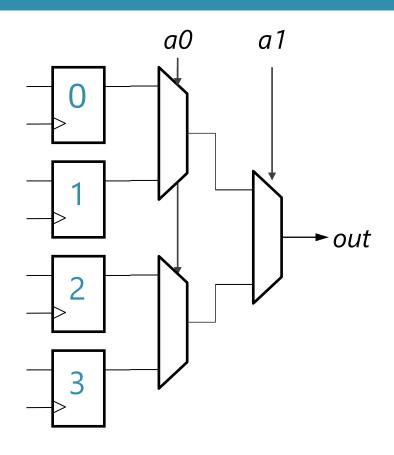
## メモリ

- 1. メモリの基本
  - 1. 構造
  - 2. 動作
  - 3. アクセス時間
- 2. メモリの詳細
  - 1. SRAM と DRAM
  - 2. なぜメモリが存在するのか?
  - 3. マルチポート・メモリ
  - 4. メモリを対象にしたアタック

#### メモリの存在する理由

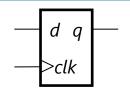
- D-FF とマルチプレクサがあれば, 等価な機能は実現できる
  - ◇ 実際には、メモリ専用の回路が用意される
- メモリ専用の回路が用意される理由:
  - ◇ D-FF とマルチプレクサよりも,高密度に実装したいから
  - ◇ 同じチップ面積で、より多くの情報を記憶したい

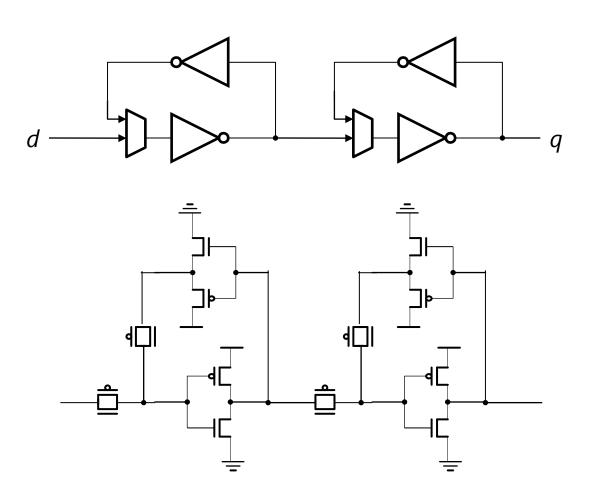
### D-FF とマルチプレクサによる 4bit の RAM



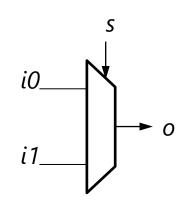
- 4エントリの LUT を D-FF で構成してみる
  - ◇ 中身を憶える 4つの D-FF
  - ◇ 場所を指定して選択する2段のマルチプレクサ

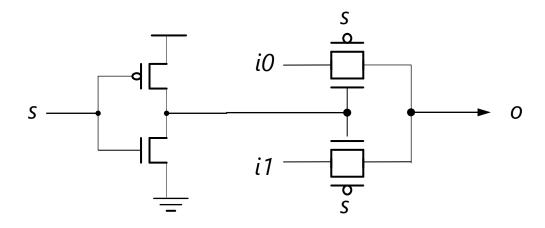
# D-FF: トランジスタ 16個





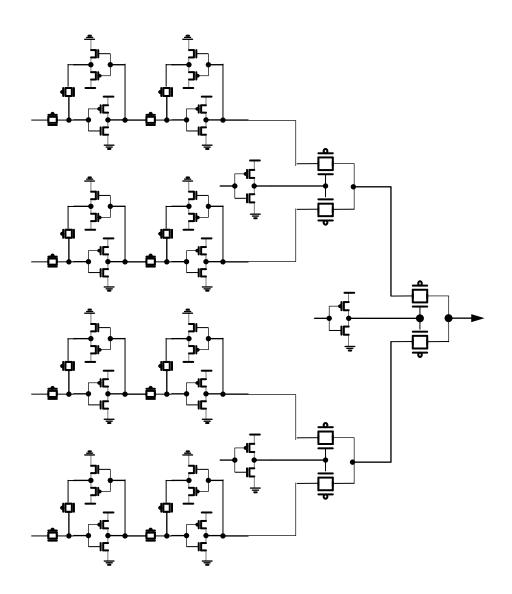
# マルチプレクサ:トランジスタ 6個



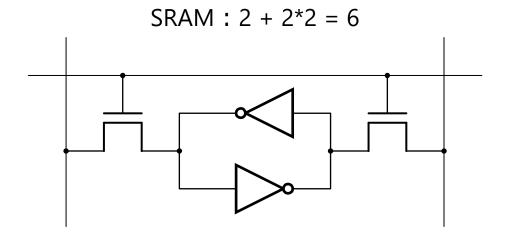


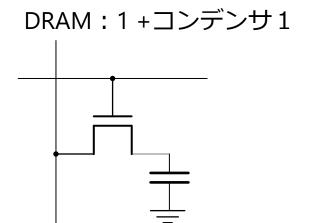
# 4bit メモリに必要なトランジスタ数:82

16\*4+6\*3=82



# SRAM と DRAM のセル (1bit)

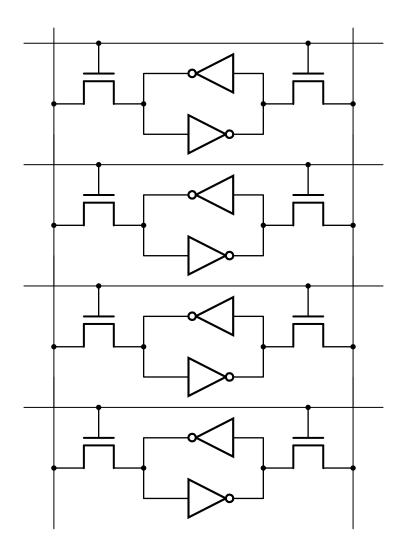




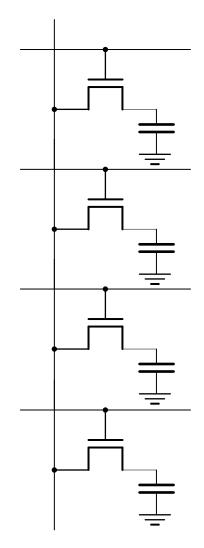
◇ D-FF よりも圧倒的に単純

# SRAM と DRAM (4bit)

SRAM: 6\*4 = 24



DRAM: 4+コンデンサ4



### メモリ

- 1. メモリの基本
  - 1. 構造
  - 2. 動作
  - 3. アクセス時間
- 2. メモリの詳細
  - 1. SRAM と DRAM
  - 2. なぜメモリが存在するのか?
  - 3. マルチポート・メモリ
  - 4. メモリを対象にしたアタック

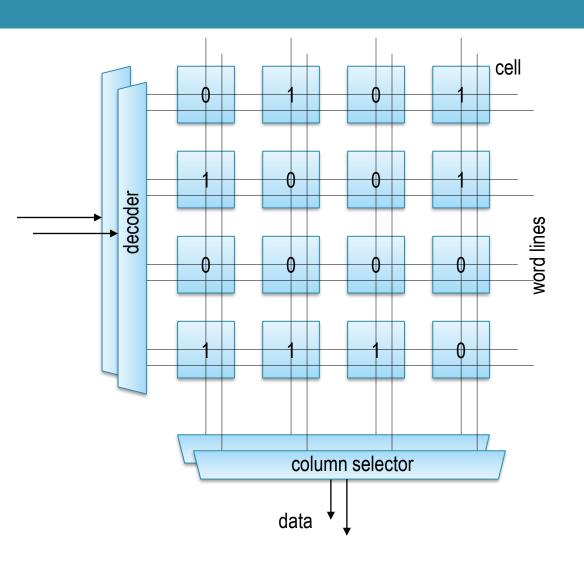
#### マルチポート・メモリ

- ランダムな複数の箇所を同時にアクセスできるメモリ
  - ◇ レジスタ・ファイルなどを作るときに必要
    - □ 2つのソースの読み出しと、ディスティネーションの書き込み
  - ◇ 同時にクセスできる数 = ポート数
- CPU に特有に良く必要になる
  - ◇ 一般的な回路ではあまり出てこない
- ポート数の2乗に比例して面積が大きくなる
  - ◇ 同時にアクセスできる数の2乗に比例する

### マルチポート・メモリの回路面積

- ポート数の2乗に比例して面積が大きくなる
  - ◇ 同時にアクセスできる数の2乗に比例する
- レジスタ・ファイルなどは、同一記憶容量あたりの回路面積が大きい

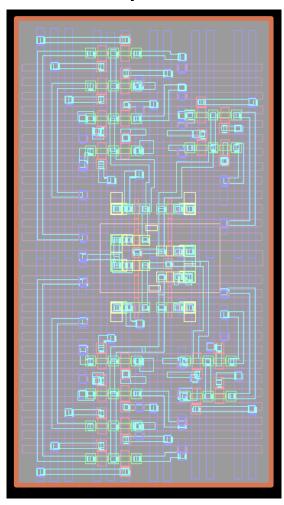
### ポート数の2乗に比例して面積が大きくなる



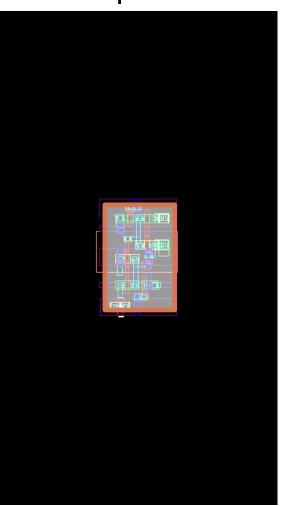
- 複数の異なる行を アクセス
  - ◇ ワードラインが 複数必要
  - ◇ ビットラインも 複数必要
- 縦と横がそれぞれ ポート数分増える
  - ◇ ポート数が増える と配線の面積が 支配的に

# SRAM (1bit) のレイアウト

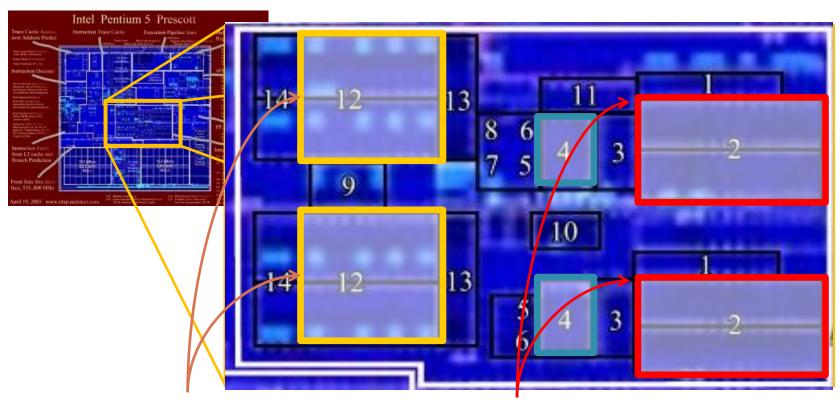
12 ports



2 ports



#### Intel Pentium 4 の整数演算ユニット



#### L1 Data cache

16KB 1 read/1 write

( from http://www.chip-architect.com)

# Register file

64 bits 144 entries 6 read/3 write (double pumped)

### マルチポート・メモリと CPU の回路規模

- CPU の性能を上げようとすると、ポート数が増える事が多い
  - ◇ 例:2命令を同時に処理できるようにする
    - □ レジスタ・ファイルの読み出しと書き込みが倍に
    - □ ポート数が倍 → 回路面積 4 倍

#### マルチポート・メモリと CPU の回路規模

- CPU はそう言ったメモリのかたまり
  - ◇ 演算器よりもメモリの方がずっと大きい
  - ◇ 投機実行や並列実行をするために様々なテーブルが導入される
  - ◇ それらは同時アクセス可能な数に対して,急速に大きくなる
- 同時実行数を増やすことが難しい
  - ◇ 完全に独立したメモリなら問題ない
  - ◇ 1つの大きなコアを作るより、お互いが独立しているマルチコア 化の方が面積効率は良い

### メモリ

#### 1. メモリの基本

- 1. 構造
- 2. 動作
- 3. アクセス時間

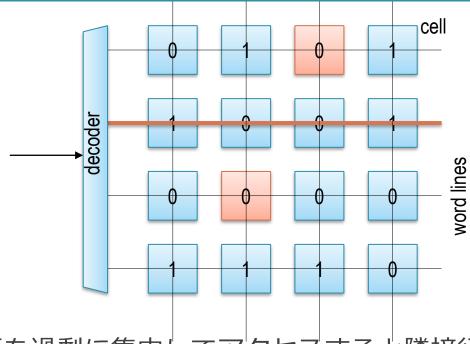
#### 2. メモリの詳細

- 1. SRAM と DRAM
- 2. なぜメモリが存在するのか?
- 3. マルチポート・メモリ
- 4. メモリを対象にしたアタック

# メモリを対象にしたアタック

- メモリの仕組みがわかると,原理がわかる
  - 1. Row Hammer
  - 2. Cold Boot Attack

#### **Row Hammer**



- 特定の行を過剰に集中してアクセスすると隣接行のデータが化ける
  - ◇ 通常よりも DRAM セルの放電が早まるため
  - ◇ 意図的にデータを化けさせて様々なアタックを行う
    - □ 特権昇格とかは実証コードがでている・・・らしい
- Yoongu Kim et al., Flipping Bits in Memory Without Accessing Them:
  An Experimental Study of DRAM Disturbance Errors など 104

#### **Cold Boot Attack**

- 稼働中のマシンの DRAM を物理的に引っこ抜いて, 他のマシンにさして読み取る
  - ◇ DRAM セルの電荷の放電は、温度が低いほどゆっくりになる
  - ◇ メモリを極低温に冷やすことで、攻撃成功率が飛躍的に上がる
  - ◇ -50 度まで冷やすと, 1時間ぐらい持つ・・・らしい
- J. A. Halderman et al., Lest we remember: Cold-boot attacks on encryption keys など

#### Cold Boot Attack の応用例

- 【ロマサガ2】ほぼ全ての技を100%閃く方法 (おやつの人, 2019)
  - https://www.youtube.com/watch?v=gWfcZnAydQ4



### ロマサガ2の技のひらめき判定(イメージ)

このゲームでは戦闘中に条件に応じて一定の確率で技をひらめく

■ // 乱数値で初期化されたテーブル uint8\_t RAND\_TABLE[256] = ...; // 乱数テーブルのインデクス // 初期化されていないので, // 直前にさしたカセットで書かれていた値が使われる uint8 t rand index; uint8 t rand() { return RAND TABLE[rand index++]; // 技のひらめき境界値より小さい乱数を引けば技をひらめく bool waza\_hirameki() { return rand() < waza threshold() ? true : false;</pre>

# 今日のまとめ

- 分岐予測の続き
- メモリの基本と詳細

#### 出欠と感想

- 本日の講義でよくわかったところ、わからなかったところ、 質問、感想などを書いてください(なんかー言書いてね)
  - ◇ LMS の出席を設定するので、そこにお願いします
  - ◇ パスワード: memory
- 意見や内容へのリクエストもあったら書いてください